Predicción de Abandono de Clientes en una Empresa de Telecomunicaciones

Pre-entrega — Proyecto Final Integrador

Diplomado en Ciencia de Datos y Análisis Avanzado

Trabajo Final Integrador

Autor: Nicolás Lombardia

21 de septiembre de 2026

1. Resumen ejecutivo

Conseguir un cliente nuevo sale más caro que conservar uno que ya está, pero las campañas de retención suelen tirarse sobre toda la base: es gastar plata en gente que no pensaba irse. En los datos que vamos a usar, uno de cada cuatro clientes terminó dándose de baja.

La idea es un modelo que estime, cliente por cliente, qué tan probable es que se vaya, para que Retención ordene la base por riesgo y concentre el esfuerzo donde hace falta. Lo usarían ese equipo y la Dirección Comercial, que necesita ver el resultado.

KPI esperado: cuánto del ingreso mensual en riesgo se logra conservar entre los clientes contactados. Como indicador secundario, cuánto baja la tasa de bajas en el grupo intervenido frente al que quedó sin acción.

2. El problema y el caso de negocio

2.1 Qué queremos lograr

Un modelo que le ponga a cada cliente una probabilidad de baja y detecte al menos 7 de cada 10 que se van, sin que más de la mitad de sus avisos sean falsas alarmas. El que ya armamos detecta poco más de la mitad: ahí está el margen.

2.2 De qué sospechamos

- El tipo de contrato es el factor más pesado: los que pagan mes a mes se van mucho más que los que firmaron por uno o dos años.
- El riesgo se concentra en los primeros meses; también pesan la factura alta, no tener soporte y pagar con cheque electrónico.
- Ordenando la base por riesgo, la mayoría de las bajas debería quedar arriba de todo, mejor de lo que logra la regla que se usa hoy.

2.3 Con qué limitaciones trabajamos

Los datos son una foto sin fechas: no sabemos de qué período son ni podemos probar el modelo contra meses posteriores. Tampoco tenemos los costos reales de la empresa. Y el archivo de prueba viene sin la respuesta: todo sale de dividir el de entrenamiento.

2.4 Qué está en juego

Lo que cuesta perderlo frente a lo que cuesta retenerlo:

Parámetro	Valor	De dónde sale
Cargo mensual promedio	USD 65	Los datos
Valor en riesgo por baja, a 12 meses	USD 780	Derivado del anterior
Costo de contactar a un cliente	USD 15	Supuesto a confirmar
Cuántos aceptan la oferta	30 %	Supuesto a confirmar

Con estos números, dejar ir a un cliente sale unas cincuenta veces más caro que molestar a alguien que se quedaba igual. Aunque los supuestos estén algo corridos, la diferencia es tan grande que la conclusión no cambia: conviene pecar de detectar de más.

3. Los datos

3.1 De dónde salen

El conjunto que dio la cátedra en la competencia de Kaggle «Predicción de fuga de cliente», derivado del dataset público Telco Customer Churn: entrenamiento con 5.634 clientes y 21 columnas, y prueba con 1.409 y 20. Son datos abiertos, anonimizados y sin problemas de licencia.

3.2 Las variables principales

Variable	Qué representa
Churn	Si el cliente se dio de baja. Es lo que queremos predecir.
tenure	Meses que lleva como cliente. De 0 a 72; promedio 32.
MonthlyCharges	Lo que paga por mes. Entre 18 y 119 dólares; promedio 65.
TotalCharges	Lo que pagó desde que entró. Llega hasta 8.685 dólares.
Contract	Si paga mes a mes, o firmó por uno o dos años.
InternetService	Si tiene DSL, fibra óptica o no tiene internet.
PaymentMethod	Cómo paga: cheque electrónico, cheque postal, transferencia o tarjeta.
TechSupport	Si contrató soporte técnico aparte.
OnlineSecurity	Si contrató el servicio de seguridad en línea.

Variable	Qué representa
PaperlessBilling	Si recibe la factura de forma electrónica.
SeniorCitizen	Si es mayor de 65 años. Es el 16 % de la base.

3.3 Cómo vienen

Razonablemente limpios: ninguna de las 21 columnas tiene celdas vacías, no hay filas repetidas ni clientes en los dos archivos. Tampoco hay valores disparatados: el total pagado se estira hacia arriba (promedio 2.301 contra mediana 1.397), pero eso es la mezcla de clientes viejos y nuevos, no un error. Dos cosas sí para mirar: el dataset original tenía blancos en el total pagado para clientes nuevos y acá no aparecen, así que alguien los completó; y ese total es casi la antigüedad por el cargo mensual, o sea que las tres dicen en parte lo mismo.

3.4 Limpieza hecha y pendiente

Hecho: sacamos el identificador, pasamos la respuesta a 0 y 1, llevamos las numéricas a una misma escala y convertimos las categóricas en columnas binarias. Todo quedó en un único flujo que se calcula solo con los datos de entrenamiento, para que la validación no vea nada de antemano.

Pendiente: revisar los clientes con antigüedad cero, decidir qué hacer con el total pagado, armar variables nuevas (cuánto paga en promedio por mes, cuántos servicios tiene) y definir cómo tratar el desbalance.

4. Cómo vamos a modelar y validar

4.1 El punto de partida

Probamos tres modelos, separando el entrenamiento en 80 % y 20 %, con la misma proporción de bajas en ambas partes:

Modelo	Aciertos	F1 (bajas)	ROC AUC	Detección
Regresión Logística	0,816	0,612	0,848	55 %
Naive Bayes	0,697	0,592	0,827	83 %
k-NN (k = 15)	0,789	0,580	0,825	55 %

La Regresión Logística es la que mejor ordena la base; Naive Bayes encuentra más bajas pero se equivoca demasiado. Resolver esa tensión es lo que falta.

4.2 Qué vamos a mirar y cómo

La métrica principal será el ROC AUC, porque mide qué tan bien ordena la base sin dejarse engañar por el hecho de que la mayoría se queda. Al lado van cuántas bajas detecta, cuántas alarmas son correctas y cuántas bajas caen dentro del 20 % más riesgoso, que es como Retención va a usarlo.

Para comparar modelos usamos validación cruzada en cinco partes, con el promedio y cuánto varía entre ellas. El 20 % apartado queda para una única prueba final del modelo elegido.

4.3 Cuándo lo damos por bueno

Un ROC AUC de 0,85 o más, detectando al menos 7 de cada 10 bajas, con la mitad o más de las alarmas bien puestas y una mejora mayor que la variación entre partes. El corte no será el 0,5 automático, sino el que permita el presupuesto de contactos.

4.4 Contra qué lo comparamos

Hoy la regla es llamar a todos los que pagan mes a mes: son el 55 % de la base y ahí está el 89 % de las bajas, pero solo 43 de cada 100 llamados se van de verdad. Ordenando por riesgo, el modelo llega a ese mismo 89 % contactando al 53 %, y dentro del 20 % más riesgoso ya encuentra la mitad de las bajas, 2,7 veces más que al azar.

5. Riesgos y próximos pasos

Al no tener fechas, no podemos descartar que alguna columna cuente algo posterior a la baja ni probar el modelo contra meses siguientes. Los supuestos de costo pueden estar lejos de la realidad: si cambian se mueve el corte, aunque el modelo sigue valiendo. Y por ser datos públicos, el impacto en plata es estimado.

Lo que sigue, en orden:

Etapa	Qué hacemos	Con qué terminamos
1	Cerrar lo pendiente de los datos y armar las variables nuevas	Base limpia y lista
2	Probar cómo tratar el desbalance y ajustar los modelos	La mejor versión de cada uno

Etapa	Qué hacemos	Con qué terminamos
3	Sumar ensambles y redes neuronales, y comparar todo	El modelo elegido
4	Elegir el punto de corte y traducirlo a plata	El impacto estimado
5	Escribir el informe y generar las predicciones	Entrega final